Qwen3.5-9B 多专家训练与模型合版实验

代码: https://github.com/ktwu01/qwen36-35b-takehome
expert-swe: https://huggingface.co/ktwu01/qwen35-9b-takehome-expert-swe (revision 6e499da)
expert-term: https://huggingface.co/ktwu01/qwen35-9b-takehome-expert-term (revision 3cde28a)
expert-sci: https://huggingface.co/ktwu01/qwen35-9b-takehome-expert-sci (revision cd65629)
merged: https://huggingface.co/ktwu01/qwen35-9b-takehome-merged (revision e1f112a)
union-control: https://huggingface.co/ktwu01/qwen35-9b-takehome-union-control (revision 2b9606c)

摘要 本实验以 Qwen3.5-9B 为基座（算力不足，按题目降至七十亿级），按评测协议训练软件修复、终端操作与科学推理三个 QLoRA 专家，在独立开发集上消融后选定 TIES 合版，并在四项基准上比较基座、专家与合版模型。合版宏平均较基座下降约四个百分点，置信区间不含零，未达提升三个百分点的目标：HLE 小幅提升，其余三项退化。误差分析显示，退化主要来自智能体动作格式与评测框架不匹配，其次是过早宣布完成与超时。

过程 因 24 GB 单卡与 超算 队列限制，按题目允许降至同系列 7B 级基座 Qwen3.5-9B（与 Qwen3.6 同为 Gated DeltaNet 混合注意力、262K 上下文、多模态）。按评测协议划分三个专家：swe（mini-swe-agent 文本动作轨迹，2,000 条，MIT）、term（Terminus-2 轨迹，2,000 条，Apache-2.0）、sci（科学推理，4,000 条，CC-BY-4.0），经长度过滤、去重、MinHash 近重复、对四项 benchmark 的 13-gram 去污染与难度分层。 三专家在 超算 A100 上以相同 QLoRA 配置（r=32，lr 1e-4，16K 上下文，1 epoch，种子 20261018）训练。 合版在独立开发集上比较任务算术、TIES、DARE-TIES 共 7 个配置，按预先固定的规则选出 TIES（密度 0.5， lambda 1.0）；对照为专家数量（2 vs 3）、训练强度（60%/66% 检查点）与三份数据并集上的单个 LoRA（同配置，单卡批量 16）： 并集模型开发集平均损失 0.314，低于合版 0.328，三个领域均更低，接近各专家本领域损失；该对照仅在 TB2 种子 1 上评测：成功率 10.11%，低于合版 12.36%（差 -2.25 个百分点，95% CI [-8.99, +4.49]）与 Base 19.10%，开发集损失优势未延续到 TB2。四项评测在相同 FP8 权重与 KV、 256K 上下文、temperature 1.0 下进行，环境为 apptainer（oracle 校验：SWE-Pro 50/51，TB2 59/89，全部任务均计入分母）。

结果 主指标为百分制；TB2 为种子均值±标准差；最后一列为合版相对 Base 的配对 bootstrap 差值（百分点，95% CI）。专家只评测其目标 benchmark（–）。

Benchmark	Base	swe 专家 仅 SWE-Pro	term 专家 仅 TB2	sci 专家 仅 HLE/ASI	合版	合版−Base
SWE-bench Pro v2-hard	5.9	0.0	–	–	0.0	-5.9 [-13.7, +0.0]
Terminal-Bench 2.0	19.1 (1种子)	–	9.0 (1种子)	–	12.4 (1种子)	-6.7 [-14.6, +1.1]
HLE	7.1	–	–	7.1	8.2	+1.1 [-0.2, +2.3]
ASI-Bench	5.8	–	–	0.5	0.5	-5.1 [-6.7, -3.7]

宏平均: Base 9.46，合版 5.26；提升 -4.17 pp (95% CI -6.92, -1.61)（目标 +3）。TB2 种子（题目要求 5 个）： base 完整 1 个（未完成：2 号 83/89，3 号 41/89）； term 完整 1 个（未完成：2 号 4/89）； merged 完整 1 个（未完成：2 号 88/89，3 号 12/89），均值只用完整种子。 **运行失败率**（非正常结束：超时、环境失败、无答案，均计入分母）: base/asi 2.5%, base/hle 51.2%, base/swe_pro 0.0%, base/tb2 27.2%, merged/asi 0.4%, merged/hle 18.0%, merged/swe_pro 0.0%, merged/tb2 20.1%, sci/asi 0.8%, sci/hle 23.4%, swe/swe_pro 0.0%, term/tb2 25.8%, union/tb2 16.9%。

成本: HPC 估计共 181.8 SU（the project allocation；A100 GPU 时 139.5），评测在 seismic 工作站约 124.6 GPU 时；无云租用费用。

说明（评测于 2026-10-19 20:20 CDT 停止；TB2 第 2、3 号种子未完成，计数见上）： ASI-Bench 智能体实际以 mini-swe-agent 工具调用模式运行，Base 用原生工具调用， sci 与合版按提示输出文本 bash 块而被拒（合版 240 次中 206 次 RepeatedFormatError），故 ASI 退化主要反映协议不匹配； SWE-Pro 的格式错误来自 vLLM qwen3 推理解析器把无 think 结束标记的回复整体归入 reasoning_content。 HLE 中因 OpenAI 429 未判分的答案（sci 71、合版 139）已用同一判分器重判。逐题结果、41 个失败案例、置信区间与日志见仓库 results/、analysis/failures.md、logs/。